



**Pontificia Universidad
Católica del Ecuador**
Seréis mis testigos

**FACULTAD DE CIENCIAS EXACTAS,
NATURALES Y AMBIENTALES**

RECONOCIMIENTO AUTOMÁTICO DE IMÁGENES PARA RECONSTRUCCIÓN DE REDES PLANTA-POLINIZADOR

Andrés Merino T.

Abril 2025

Facultad de Ciencias Exactas, Naturales y Ambientales

CONTENIDO

1. Motivación
2. ¿Qué es una imagen?
3. Redes convolucionales
4. Implementación del trabajo
5. Conclusiones y trabajo futuro





**Pontificia Universidad
Católica del Ecuador**
Seréis mis testigos

**FACULTAD DE CIENCIAS EXACTAS,
NATURALES Y AMBIENTALES**

MOTIVACIÓN



¿CUÁL ES MÁS FÁCIL?

Opción B

¿En cuál imagen hay una *Pristimantis croceoinguinis*?



Foto: Santiago Ron-BIOWEB, <https://bioweb.bio>.

Opción A

Calcular:
 6×2

¿CUÁL ES MÁS FÁCIL?

Opción A

Calcular:

695 951

× 154 465 122

× 111 154 465,122

× 1 514 616 454 651

Opción B

¿En cuál imagen hay un perro?





**Pontificia Universidad
Católica del Ecuador**
Seréis mis testigos



FACULTAD DE CIENCIAS EXACTAS,
NATURALES Y AMBIENTALES

¿QUÉ ES UNA IMAGEN?




¿QUÉ ES UNA IMAGEN?

Una imagen digital se representa como una matriz de valores, donde cada elemento (píxel) de la matriz almacena la intensidad de luz en un punto específico de la imagen.



EL FORMATO RGB

- Modelo de color basado en la síntesis aditiva
- Es posible representar un color mediante la mezcla por adición de los tres colores de luz primarios: rojo, verde o azul.
- Tiene rangos de 0 a 255 (enteros) o de 0 a 1 (reales).




EJEMPLO


$$R = \begin{pmatrix} 0,0 & 0,3 & 0,9 \\ 1,0 & 0,0 & 1,0 \end{pmatrix}; \quad G = \begin{pmatrix} 0,0 & 0,3 & 0,3 \\ 0,0 & 1,0 & 1,0 \end{pmatrix}; \quad B = \begin{pmatrix} 0,0 & 0,3 & 0,9 \\ 0,0 & 0,0 & 1,0 \end{pmatrix}.$$

EJEMPLO


$$R = \begin{pmatrix} 0,0 & 0,3 & 0,9 \\ 1,0 & 0,0 & 1,0 \end{pmatrix}; \quad G = \begin{pmatrix} 0,0 & 0,3 & 0,3 \\ 0,0 & 1,0 & 1,0 \end{pmatrix}; \quad B = \begin{pmatrix} 0,0 & 0,3 & 0,9 \\ 0,0 & 0,0 & 1,0 \end{pmatrix}.$$



MEJORAR IMÁGENES



82	81	82
81	200	83
80	83	84




82	81	82
81	82	83
80	83	84

UN PAR MÁS DE CONCEPTOS

Bounding Box

- Delimita un objeto dentro de una imagen utilizando un rectángulo.
- Proporciona coordenadas (x, y) y dimensiones (ancho, alto) del rectángulo.



UN PAR MÁS DE CONCEPTOS

Segmentación Semántica

- Asigna una etiqueta a cada píxel de la imagen, clasificándolos según el tipo de objeto al que pertenecen.
- Proporciona una delimitación precisa de los contornos de los objetos.



¿CÓMO APRENDE UNA MÁQUINA A INTERPRETAR UNA IMAGEN?

Una imagen no es más que una tabla de números.

¿Cómo puede una computadora aprender, a partir de esos números, que está viendo una abeja, una mariposa o una flor?

¿CÓMO APRENDE UNA MÁQUINA A INTERPRETAR UNA IMAGEN?

Una imagen no es más que una tabla de números.

¿Cómo puede una computadora aprender, a partir de esos números, que está viendo una abeja, una mariposa o una flor?

La respuesta: **redes neuronales convolucionales**.



**Pontificia Universidad
Católica del Ecuador**
Seréis mis testigos


FACULTAD DE CIENCIAS EXACTAS,
NATURALES Y AMBIENTALES

REDES CONVOLUCIONALES



REDES CONVOLUCIONALES

- Se inspiran en la corteza visual de los animales.
- Desarrollo desde Neocognitron (Fukushima, 1982) a LeNet-5 (LeCun, 1989).
- Avance impulsado por hardware mejorado y algoritmos optimizados a partir de 2012.
- CNNs aplican filtros convolucionales para extraer patrones como bordes, texturas, y formas a diferentes niveles de abstracción.



Fuente: <https://www.quantamagazine.org/>

ESTRUCTURA DE UNA RED NEURONAL CONVOLUCIONAL (CNN)

- **Bloque convolucional:**

- Incluye capas de convolución, agrupamiento (pooling) y activación.
- Detecta patrones y características en los datos de entrada.


- **Bloque totalmente conectado:**

- Cada neurona se conecta con todas las neuronas de la capa anterior y siguiente.
- Correlacionan las características detectadas por las capas convolucionales.


- **Bloque de decisión:**

- Genera un vector de probabilidades para cada clase.
- Usa funciones como softmax.


ESTRUCTURA DE UNA RED NEURONAL CONVOLUCIONAL (CNN)



ESTRUCTURA DE UNA RED NEURONAL CONVOLUCIONAL (CNN)



EJEMPLO DE UNA CNN: LENET-5



PARÁMETROS DE LeNET-5

Capa	Dimensión	Tamaño	Parámetros
Input	$(32 \times 32 \times 3)$	3072	0
Conv1	$(28 \times 28 \times 6)$	4704	456
Pool1	$(14 \times 14 \times 6)$	1176	0
Conv2	$(10 \times 10 \times 16)$	1600	2416
Pool2	$(5 \times 5 \times 16)$	400	0
FC2	(120×1)	120	48120
FC3	(84×1)	84	10164
Softmax	(10×1)	10	850
Total			62006

TRANSFERENCIA DEL APRENDIZAJE

- Permite reutilizar un modelo entrenado en una tarea para aplicarlo en otra tarea similar.
- Mejora el rendimiento del modelo y acelera el progreso.
- Es popular en **Deep Learning** debido a los altos costos computacionales y de datos necesarios para entrenar modelos desde cero.
- La técnica más común es usar un **modelo pre-entrenado** y adaptarlo:
 - Seleccionar el modelo fuente.
 - Reutilizar todo o parte del modelo.
 - Ajustar el modelo a la nueva tarea (fine-tuning).

¿Y EN LA PRÁCTICA?

Con redes convolucionales y transferencia del aprendizaje disponemos de herramientas muy poderosas para analizar imágenes.

¿Y EN LA PRÁCTICA?

Con redes convolucionales y transferencia del aprendizaje disponemos de herramientas muy poderosas para analizar imágenes.

Con esta ideas, podemos **detectar polinizadores en imágenes de flores.**



**Pontificia Universidad
Católica del Ecuador**

Seréis mis testigos

FACULTAD DE CIENCIAS EXACTAS,
NATURALES Y AMBIENTALES

IMPLEMENTACIÓN DEL TRABAJO



EL PROBLEMA

Objetivo

Entrenar una red neuronal para **detectar y clasificar polinizadores** en imágenes de flores, y usar esas detecciones para reconstruir automáticamente redes de interacción **planta-polinizador**.

EL PROBLEMA


Objetivo


Entrenar una red neuronal para **detectar y clasificar polinizadores** en imágenes de flores, y usar esas detecciones para reconstruir automáticamente redes de interacción **planta-polinizador**.

- **Datos:** 5 445 imágenes con polinizadores identificados manualmente.
- **Modelo:** YOLOv5 con transferencia del aprendizaje.
- **Meta:** reproducir la red ecológica real con la mayor fidelidad posible.


PROCESAMIENTO DE DATOS

- **Recolección:** Estudio de Serra (2022) con identificación por humanos.
- **Selección de Imágenes:** 5445 imágenes de flores con polinizadores.
- **Preparación:** Estandarización de dimensiones, uso de archivos XML para información de polinizadores.
- **Categorización:** Clasificación de polinizadores en 7 categorías.





SUBMUESTREO Y AUMENTO DE DATOS





ANÁLISIS INICIAL CON YOLOv5

- Prueba inicial con YOLOv5 entrenado en COCO (sin polinizadores).
- Detecciones variadas, con poca referencia a plantas y sin insectos.







Objeto	Cantidad
no detection	853
bird	322
banana	109
dining table	98
apple	67
...	...

ENTRENAMIENTO Y EVALUACIÓN DE YOLOV5

- Entrenamiento: 100 épocas, lote de 32 imág., ancho de 1280 px.
- Curvas de precisión-confianza y exhaustividad-confianza.




COMPARACIÓN DE RESULTADOS EN VALIDACIÓN



MATRIZ DE CONFUSIÓN EN PRUEBA

- Precisión en «Bee» y «Hoverfly».
- Variabilidad en la detección de insectos.



MÉTRICAS DE PRECISIÓN Y EXHAUSTIVIDAD

- Alta precisión en todas las categorías, destacando en «Lepidoptera» con 0.98.
- Variabilidad significativa en la exhaustividad, con diferencias notables entre categorías.
- Exactitud global del modelo: 58 %.

Categoría	Precisión	Exhaustividad
Bee	0.96	0.56
Coleoptera	0.90	0.45
Diptera	0.85	0.64
Hoverfly	0.80	0.80
Lepidoptera	0.98	0.75
Others	0.79	0.54
Wasp	0.82	0.66


EXACTITUD EN FUNCIÓN DEL TAMAÑO DE LOS INSECTOS

Área mínima (%)	Cantidad de imágenes	Exactitud general
0.0	1891	0.58
0.1	1795	0.61
0.5	1489	0.66
1.0	1233	0.67
2.5	812	0.71
5.0	502	0.72


- Mayor exactitud lograda con insectos que ocupan más del 2.5 % del área total de la imagen.

RESULTADOS TAMAÑO DE LOS INSECTOS 2 %


Categoría	Prec.	Exhaus.
Bee	0.94	0.64
Coleoptera	0.88	0.60
Diptera	0.92	0.76
Hoverfly	0.88	1.00
Lepidoptera	0.98	0.87
Others	0.72	0.47
Wasp	0.86	0.73




RED DE POLINIZADORES: MATRIZ DE INTERACCIONES



RED DE POLINIZADORES: PROBABILIDAD DE CONEXIÓN



COMPARACIÓN DE REDES



COMPARACIÓN DE REDES

Métrica	Red real	Red estimada
Nodos	24	21
Aristas	28	25
Densidad	0.101	0.119
Grado medio	2.33	2.38

Distancia	Valor
Error de desplazamiento	0.053
Similitud del coseno	0.972



**Pontificia Universidad
Católica del Ecuador**

Seréis mis testigos

FACULTAD DE CIENCIAS EXACTAS,
NATURALES Y AMBIENTALES

CONCLUSIONES Y TRABAJO FUTURO



CONCLUSIONES DEL ESTUDIO

- Desarrollo exitoso de una red neuronal (YOLOv5).
- Capacidad notable de YOLOv5 para detectar y clasificar polinizadores, con algunas limitaciones.
- Uso de un tamaño mínimo de detección mejora la precisión del modelo.

RESULTADOS Y ANÁLISIS DE REDES

- Métricas indican reproducción fiel de la red planta-polinizador por el modelo.
- Diferencias mínimas entre redes real y estimada, sugiriendo fiabilidad del modelo para estimación de redes ecológicas.

RECOMENDACIONES PARA TRABAJOS FUTUROS

- Explorar nuevas técnicas y modelos para mejorar detección y clasificación de polinizadores.
- Ampliar base de datos con más variedades de polinizadores y plantas.
- Aplicar modelos en conservación de la biodiversidad y estudios de interacciones planta-polinizador.
- Desarrollar protocolos para la detección de imágenes y la construcción de redes planta-polinizador.



**Pontificia Universidad
Católica del Ecuador**

Seréis mis testigos

Gracias



Presentación

Contacto: aemerinot@puce.edu.ec